

The background of the slide features a dark, textured surface. On the left, several teal lines with a dashed texture flow horizontally. A single orange line with a solid texture weaves through these, entering a central cluster of nodes. This cluster consists of numerous small teal nodes connected by thin lines, with a few orange nodes highlighted within it. To the right of the cluster, the teal lines continue as wavy, flowing shapes, and a single orange line curves upwards and to the right.

Optimizasyon

Özgür Martin

Motivasyon: Doğrusal Bağlanım

$$y_i \approx \underbrace{\hat{\beta}_0 + \hat{\beta}_1 x_i}_{\hat{y}_i}, \quad i = 1, \dots, n$$

$$e_i = y_i - \hat{y}_i \quad i. \text{ kalıntı (} i\text{th residual)}$$

Kalıntı Kareler Toplamı (Residual Sum of Squares)

$$\text{KKT} = e_1^2 + e_2^2 + \dots + e_n^2$$

(Amaç: Bu toplamı minimize eden $\hat{\beta}_0$ ve $\hat{\beta}_1$ değerlerini bulalım)

En Küçük Kareler (EKK) Yöntemi (Least Squares Method)

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \text{KKT} = \min_{\beta_0, \beta_1} (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

Minimize edilmek istenen fonksiyon basit (doğrusal) olduğundan analitik bir çözüm bulabildik:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Burada $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ve $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$

Peki fonksiyon karmaşık olsaydı? Lojistik Bağlanım? SVM?

Yaklaşık (Nümerik) çözüm?

Kısıtsız Optimizasyon (Tek Değişkenli)

Problem:

$$\min_{w \in \mathbb{R}} f(w) = \min_{w \in \mathbb{R}} \sum_{i=1}^n f_i(w; x_i, y_i)$$


Hatırlatma:

En Küçük Kareler (EKK) Yöntemi (Least Squares Method)

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \text{KKT} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

Cözüm:

Dışbükey Fonksiyon




Tanımlar

Tanım


$S \in \mathbb{R}^n$ kümesinin **dışbükey (convex)** olması için S kümesinden herhangi iki noktayı birleştiren doğru parçasının tamamının S kümesinde olması gerekir. Matematiksel olarak gösterirsek, her $x, y \in S$ çifti ve tüm $\alpha \in [0, 1]$ değerleri için

$$\alpha x + (1 - \alpha)y \in S$$

olmalıdır.



Dışbükey küme




Dışbükey olmayan küme

Tanım

$f(\cdot)$ ile gösterilen bir fonksiyonun **dışbükey** olması için tanım kümesinin dışbükey olması ve bu kümeden seçilen herhangi x, y çifti için $f(\cdot)$ grafiğinin $(x, f(x))$ ve $(y, f(y))$ noktalarını birleştiren doğru parçasının altında kalması gerekir. Matematiksel olarak ifade edersek, her x, y ve tüm $\alpha \in [0, 1]$ değerleri için

$$f(\alpha x + (1 - \alpha)y) \leq \alpha f(x) + (1 - \alpha)f(y)$$

eşitsizliği sağlanmalıdır.



- ▶ Bir $f(\cdot)$ fonksiyonunun içbükey (concave) olması, $-f(\cdot)$ fonksiyonunun dışbükey olduğunu gösterir.
- ▶ Dışbükey bir fonksiyon ile yazılan kısıtsız problemlerde lokal minimum noktası, global minimum noktası olur.
- ▶ Kabaca söylemek gerekirse, pek çok durumda dışbükey fonksiyonlar ile çalışıldığında minimum noktasını belirlemek için kullanılan gerek şartlar aynı zamanda yeter şartlar olurlar.
- ▶ Dışbükey fonksiyonlar, lokal olarak daha karmaşık ve dışbükey olmayan fonksiyonların yaklaşık gösteriminde kullanılırlar.


İkiye Bölme Yöntemi

$f: \mathbb{R} \rightarrow \mathbb{R}$, $f(L) < 0$ ve $f(U) > 0$ olmak üzere, $[L, U]$ kümesi üzerinde f fonksiyonunun bir kökünü arıyoruz.


İkiye Bölme Yöntemi

1. Orta noktayı bul: $M = \frac{L+U}{2}$.
2. $f(M)$ değerini hesapla.
3. Bulduğumuz değere göre:
 $f(M) < 0$ ise $L = M$
 $f(M) > 0$ ise $U = M$
 $f(M) = 0$ ise $L = M$ ve $U = M$
4. $[L, U]$ yeterince küçük olana kadar devam et.


İkiye Bölme Yöntemi




İkiye Bölme Yöntemi



İkiye Bölme Yöntemi



İkiye Bölme Yöntemi




İkiye Bölme Yöntemi ile Optimizasyon

$f: \mathbb{R} \rightarrow \mathbb{R}$, $f'(L) < 0$ ve $f'(U) > 0$ olmak üzere, $[L, U]$ kümesi üzerinde f fonksiyonunun en küçük değerini arıyoruz (fonksiyon dışbükey ise $f'(x) = 0$ olan x noktasını).


İkiye Bölme Yöntemi

1. Orta noktayı bul: $M = \frac{L+U}{2}$.
2. $f'(M)$ değerini hesapla.
3. Bulduğumuz değere göre:
 $f'(M) < 0$ ise $L = M$
 $f'(M) > 0$ ise $U = M$
 $f'(M) = 0$ ise $L = M$ ve $U = M$
4. $[L, U]$ yeterince küçük olana kadar devam et.


İkiye Bölme Yöntemi ile Optimizasyon




İkiye Bölme Yöntemi ile Optimizasyon




İkiye Bölme Yöntemi ile Optimizasyon



İkiye Bölme Yöntemi ile Optimizasyon



İkiye Bölme Yöntemi ile Optimizasyon




Gradyan İniş Yöntemi

Dışbükey, sürekli olarak türevlenebilen $f: \mathbb{R} \rightarrow \mathbb{R}$ fonksiyonu için $f'(x) = 0$ olan x noktasını arıyoruz. Bu koşulu sağlayan x noktası hem local hem global minimum noktası olur.

Gradyan İniş Yöntemi

1. Herhangi bir x noktasından başla.
2. Bir öğrenme hızı c seç.
3. $f'(x)$ değerini hesapla.
4. Bulduğumuz değere göre:
 $f'(x) < 0$ ise $x = x + c$
 $f'(x) > 0$ ise $x = x - c$
 $f'(x) = 0$ ise $x = x$
5. $f'(x)$ yeterince küçük olana kadar devam et.




Gradyan İnişi Yöntemi

Dışbükey, sürekli olarak türevlenebilen $f: \mathbb{R} \rightarrow \mathbb{R}$ fonksiyonu için $f'(x) = 0$ olan x noktasını arıyoruz. Öğrenme hızı c 'yi türevin mutlak değeri ile çarpıp kullanalım!

Gradyan İnişi Yöntemi

1. Herhangi bir x noktasından başla.
2. Bir öğrenme hızı c seç.
3. $f'(x)$ değerini hesapla.
4. Bulduğumuz değere göre:
 $f'(x) < 0$ ise $x = x + c |f'(x)|$
 $f'(x) > 0$ ise $x = x - c |f'(x)|$
 $f'(x) = 0$ ise $x = x$
5. $f'(x)$ yeterince küçük olana kadar devam et.




Gradyan İnişi Yöntemi

Dışbükey, sürekli olarak türevlenebilen $f: \mathbb{R} \rightarrow \mathbb{R}$ fonksiyonu için $f'(x) = 0$ olan x noktasını arıyoruz. Öğrenme hızı c 'yi türevin mutlak değeri ile çarpıp kullanalım!

Gradyan İnişi Yöntemi

1. Herhangi bir x noktasından başla.
2. Bir öğrenme hızı c seç.
3. $f'(x)$ değerini hesapla.
4. Bulduğumuz değere göre:
 $f'(x) < 0$ ise $x = x - c f'(x)$
 $f'(x) > 0$ ise $x = x - c f'(x)$
 $f'(x) = 0$ ise $x = x$
5. $f'(x)$ yeterince küçük olana kadar devam et.




Gradyan İniş Yöntemi


Dışbükey, sürekli olarak türevlenebilen $f: \mathbb{R} \rightarrow \mathbb{R}$ fonksiyonu için $f'(x) = 0$ olan x noktasını arıyoruz. Öğrenme hızı c 'yi türevin mutlak değeri ile çarpıp kullanalım!

Gradyan İniş Yöntemi


1. Herhangi bir x noktasından başla.
2. Bir öğrenme hızı c seç.
3. $x = x - c f'(x)$
4. $|f'(x)|$ yeterince küçük olana kadar devam et.




Öğrenme hızını doğru seçmezsek algoritma çalışmayabilir!




Öğrenme hızını doğru seçmezsek algoritma çalışmayabilir!




Öğrenme hızını doğru seçmezsek algoritma çalışmayabilir!




Öğrenme hızını doğru seçmezsek algoritma çalışmayabilir!



Öğrenme hızını doğru seçmezsek algoritma çalışmayabilir!



Öğrenme hızını doğru seçmezsek algoritma çalışmayabilir!



Kısıtsız Çok Değişkenli Optimizasyon


Dışbükey $f: \mathbb{R}^n \rightarrow \mathbb{R}$ fonksiyonunun birinci dereceden kısmi türevleri var ve sürekli olsun

Gradyan vektörü:

$$\nabla f(x) = \begin{bmatrix} \frac{\partial f(x)}{\partial x_1} \\ \frac{\partial f(x)}{\partial x_2} \\ \vdots \\ \frac{\partial f(x)}{\partial x_n} \end{bmatrix}$$



Hatırlatma: f fonksiyonun bir $x \in \mathbb{R}^n$ noktasında en hızlı azaldığı yön gradyanın ter yönüdür, yani $-\nabla f(x)$.

Amaç: Lokal minimumlardan bir tanesine ulaşmak. Bu noktalarda $\nabla f(x) = 0$.



Hatırlatma: Dışbükey fonksiyonlarda tek bir lokal minimum var. Bu aynı zamanda global minimum.


Dışbükey Fonksiyon



Gradyan İnişi Yöntemi (Tek Değişken)

Gradyan İnişi Yöntemi

1. Herhangi bir x noktasından başla.
2. Bir öğrenme hızı c seç.
3. $x = x - c f'(x)$
4. $|f'(x)|$ yeterince küçük olana kadar devam et.




Gradyan İnişi Yöntemi (Çok Değişken)


Dışbükey, bütün kısmi türevleri var ve sürekli olan bir $f: \mathbb{R}^n \rightarrow \mathbb{R}$ fonksiyonu için $\nabla f(x) = 0$ eşitliğini sağlayan $x \in \mathbb{R}^n$ noktasını arıyoruz.

Gradyan İnişi Yöntemi


1. Herhangi bir $x \in \mathbb{R}^n$ noktasından başla.
2. Bir öğrenme hızı c seç.
3. $x = x - c \nabla f(x)$
4. $\|\nabla f(x)\|$ yeterince küçük olana kadar devam et.




Gradyan İnişi Yöntemi (Çok Değişken)




Gradyan İnişi Yöntemi (Çok Değişken)



Gradyan İnişi Yöntemi (Çok Değişken)



Gradyan İnişi Yöntemi (Çok Değişken)



Uygulama: Doğrusal Bağlanım

$$y_i \approx \underbrace{\hat{\beta}_0 + \hat{\beta}_1 x_i}_{\hat{y}_i}, \quad i = 1, \dots, n$$

$$e_i = y_i - \hat{y}_i \quad i. \text{ kalıntı (} i\text{th residual)}$$

Kalıntı Kareler Toplamı (Residual Sum of Squares)

$$\text{KKT} = e_1^2 + e_2^2 + \dots + e_n^2$$

(Amaç: Bu toplamı minimize eden $\hat{\beta}_0$ ve $\hat{\beta}_1$ değerlerini bulalım)

En Küçük Kareler (EKK) Yöntemi (Least Squares Method)

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \text{KKT} = \min_{\hat{\beta}_0, \hat{\beta}_1} (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

Minimize edilmek istenen fonksiyon basit (doğrusal) olduğundan analitik bir çözüm bulabildik:

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sum_{i=1}^n (x_i - \bar{x})^2}$$

$$\hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

Burada $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$ ve $\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i$

Şimdi analitik çözüm yerine **gradian iniş yöntemi** ile minimizasyon problemini çözelim?

Gradyan İniş İle Çözüm

Problem:



$$\min_{(\hat{\beta}_0, \hat{\beta}_1) \in \mathbb{R}^2} f(\hat{\beta}_0, \hat{\beta}_1)$$

En Küçük Kareler (EKK) Yöntemi (Least Squares Method)

$$\min_{\hat{\beta}_0, \hat{\beta}_1} \text{KKT} = (y_1 - \hat{\beta}_0 - \hat{\beta}_1 x_1)^2 + (y_2 - \hat{\beta}_0 - \hat{\beta}_1 x_2)^2 + \dots + (y_n - \hat{\beta}_0 - \hat{\beta}_1 x_n)^2$$

Çözüm:

Dışbükey Fonksiyon



Problem:

$$\min_{(\hat{\beta}_0, \hat{\beta}_1) \in \mathbb{R}^2} f(\hat{\beta}_0, \hat{\beta}_1)$$

$$f(\hat{\beta}_0, \hat{\beta}_1) = \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2$$


$$\begin{aligned} \nabla f(\hat{\beta}_0, \hat{\beta}_1) &= \begin{bmatrix} \frac{\partial f}{\partial \hat{\beta}_0} \\ \frac{\partial f}{\partial \hat{\beta}_1} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n \frac{\partial}{\partial \hat{\beta}_0} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 \\ \sum_{i=1}^n \frac{\partial}{\partial \hat{\beta}_1} (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i)^2 \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n -2(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) \\ \sum_{i=1}^n -2x_i(y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) \end{bmatrix} \\ &= \begin{bmatrix} -2 \sum_{i=1}^n y_i + 2n\hat{\beta}_0 + 2\hat{\beta}_1 \sum_{i=1}^n x_i \\ -2 \sum_{i=1}^n x_i y_i + 2\hat{\beta}_0 \sum_{i=1}^n x_i + 2\hat{\beta}_1 \sum_{i=1}^n x_i^2 \end{bmatrix} \end{aligned}$$

Gradyan İnişi Yöntemi

Dışbükey, bütün kısmi türevleri var ve sürekli olan bir $f: \mathbb{R}^n \rightarrow \mathbb{R}$ fonksiyonu için $\nabla f(x) = 0$ eşitliğini sağlayan $x \in \mathbb{R}^n$ noktasını arıyoruz.

Gradyan İnişi Yöntemi

$$x^{(k)} = x^{(k-1)} - c \nabla f(x^{(k-1)})$$



Gradyan İnişi Yöntemi


Dışbükey, bütün kısmi türevleri var ve sürekli olan bir $f: \mathbb{R}^n \rightarrow \mathbb{R}$ fonksiyonu için $\nabla f(x) = 0$ eşitliğini sağlayan $x \in \mathbb{R}^n$ noktasını arıyoruz.

Gradyan İnişi Yöntemi

İstersek öğrenme hızını her adımda değiştirebiliriz: c yerine c_k

$$x^{(k)} = x^{(k-1)} - c_k \nabla f(x^{(k-1)})$$

Mesela: $c_k = \frac{1}{k}$ veya $c_k = \frac{1}{\sqrt{k}}$



Stokastik Gradyan İnişi Yöntemi

Problem:

$$\min_x \frac{1}{m} \sum_{i=1}^m f_i(x)$$

Uygulamada m veri noktası sayısı. Mesela KKT.

Burada

$$\nabla \sum_{i=1}^m f_i(x) = \sum_{i=1}^m \nabla f_i(x)$$

Gradyan İniş Yöntemi:

$$x^{(k)} = x^{(k-1)} - t_k \cdot \frac{1}{m} \sum_{i=1}^m \nabla f_i(x^{(k-1)}), \quad k = 1, 2, 3, \dots$$

Her adımda m tane gradyan hesabı yapmamız gerekiyor. Büyük veriler için çok masraflı!

Stokastik Gradyan İnişi Yöntemi


Problem:

$$\min_x \frac{1}{m} \sum_{i=1}^m f_i(x)$$


Rassal Gradyan İnişi Yöntemi

$$x^{(k)} = x^{(k-1)} - c_k \cdot \nabla f_{i_k}(x^{(k-1)})$$


burada $i_k \in \{1, \dots, m\}$ her adımda düzgün dağılıma göre rasgele seçilsin.



Gradyan İniş – Stokastik Gradyan İniş




Gradient Descent



Stochastic Gradient Descent

Karmaşa Bölgesi (Region of Confusion)

Sonlu toplamli hata fonksiyonundaki bütün fonksiyonların minimum değerlerini $w_{i,*}$ Noktasında alan ikinci dereceden polinomlar olduğunu varsayalım.



Eğitim ve Test Verisi

Sample points: $\{(x_1, y_1), \dots, (x_n, y_n)\} \subset \mathbb{R}^{d_x} \times \mathbb{R}$

$$A \subset \{1, \dots, n\}$$

Training points

$$\{(x_i, y_i)\}_{i \in A}$$

Solve

$$\min \frac{1}{|A|} \sum_{i \in A} f_i(w)$$

} Training Function

$$B = \{1, \dots, n\} \setminus A$$

Test Points


$$\{(x_i, y_i)\}_{i \in B}$$

Check

$$\frac{1}{|B|} \sum_{i \in B} f_i(w)$$


} Testing Function

Flat vs Sharp Minima



*Keskar et al. 2017

Gradyan İniş – Stokastik Gradyan İniş



Deep Convolutional
Neural Net on CIFAR-10

*Keskar et al. 2017